

RAG — Retrieval-Augmented Generation

Pesquisa 01 · O que é, tipos e características

01 RAG — Retrieval-Augmented Generation

Imagine que você está estudando para uma prova e pode consultar qualquer livro da biblioteca a qualquer momento. Você não precisa memorizar tudo — só precisa saber *onde buscar* a informação certa e depois usar seu raciocínio para responder. É exatamente isso que o RAG faz com a Inteligência Artificial.

RAG, que em português significa Geração Aumentada por Recuperação, é uma técnica que combina dois mundos: a capacidade de *buscar informações externas* (como um motor de pesquisa) com a capacidade de *gerar respostas inteligentes* (como um modelo de linguagem). O resultado é uma IA muito mais precisa, atualizada e confiável.

Por que o RAG surgiu?

Os modelos de linguagem tradicionais — aqueles que só foram treinados uma vez e nunca atualizam seu conhecimento — têm um problema sério: eles "esquecem" tudo que aconteceu depois do seu treinamento e às vezes até inventam informações (esse fenômeno é chamado de *alucinação*). O RAG veio exatamente para resolver isso, conectando o modelo a fontes de dados atuais e confiáveis.

Como o RAG funciona — o fluxo completo

Antes de ver o diagrama, vamos entender os termos que aparecem no processo:

→ Query

É simplesmente a pergunta ou solicitação do usuário. Quando você digita "Como funciona o sistema solar?" para uma IA, isso é a sua *query*. Pense nela como o pedido que você faz ao sistema.

→ Embedding Model

É um modelo especializado que transforma texto em números (vetores). Mas não qualquer número — esses números representam o *significado* do texto. Palavras com significados parecidos geram números parecidos. É como traduzir o idioma humano para o idioma matemático que o computador entende profundamente.

→ VectorDB (Banco de Dados Vetorial)

É o arquivo inteligente onde ficam guardados todos os textos já convertidos em números. Ao contrário de um banco de dados comum (que busca pela palavra exata), o VectorDB consegue encontrar textos pelo *significado* — mesmo que as palavras sejam diferentes. Vamos falar muito mais sobre ele na Pesquisa 2!

→ Retrieved Contexts

São os trechos de texto recuperados que o sistema encontrou como mais relevantes para responder à pergunta. É como se o sistema fosse até a biblioteca, selecionasse os 3 melhores parágrafos sobre o assunto e os entregasse para o modelo ler antes de responder.


→ LLM (Large Language Model)

É o modelo de linguagem grande — o "cérebro" da IA que vai, de fato, formular a resposta. Exemplos famosos: ChatGPT (da OpenAI), Gemini (do Google) e Claude (da Anthropic). Ele recebe a pergunta *mais* os contextos recuperados e gera uma resposta inteligente.

→ Response

É a resposta final gerada pelo LLM. Ela é muito mais precisa do que uma resposta gerada "do nada" porque o modelo teve acesso a informações concretas e atualizadas antes de responder.

Agora que você conhece os termos, veja como tudo se encaixa no fluxo do RAG:



Analogia do dia a dia: Pense no RAG como um estudante preparado para uma prova oral. Quando o professor faz uma pergunta (Query), o estudante vai até suas anotações (VectorDB), pega os trechos mais relevantes (Retrieved Contexts) e, com base neles, elabora uma resposta com suas próprias palavras (Response via LLM). Ele não "chuta" — ele busca, lê e então responde.

Os principais tipos de RAG

O RAG evoluiu bastante desde sua criação. Hoje existem diferentes variações, cada uma com suas características e aplicações:

RAG Básico (Naive RAG)

O modelo original e mais simples. A pergunta é transformada em vetor, os documentos mais parecidos são buscados no banco, e o LLM responde com base neles. Funciona bem para casos simples, mas tem limitações em perguntas mais complexas.

RAG Avançado (Advanced RAG)

Uma versão aprimorada que melhora tanto a fase de busca (pré-recuperação) quanto o que acontece após encontrar os documentos (pós-recuperação). Utiliza técnicas como reordenação dos resultados e filtragem de qualidade para respostas mais precisas.

RAG Modular

O mais flexível dos três. Permite trocar, adicionar ou remover partes do sistema como se fossem peças de LEGO. Você pode trocar o banco de dados, o modelo de busca ou o LLM de forma independente, adaptando-se a cada situação.

RAG com Grafos (Graph RAG)

Em vez de buscar documentos soltos, esse tipo usa um grafo de conhecimento — uma rede de conexões entre conceitos. É muito eficaz quando as perguntas envolvem relações entre entidades, como "quem trabalha com quem" ou "qual produto pertence a qual categoria".

RAG Híbrido

Combina dois tipos de busca ao mesmo tempo: a busca por palavras-chave (busca léxica, como o Google) e a busca por significado (busca semântica, via vetores). Assim, ele captura tanto quem usa a palavra exata quanto quem pergunta com outras palavras.

Self-RAG

Uma variação onde o próprio modelo decide se precisa ou não buscar informações externas. Para perguntas simples do tipo "quanto é 2+2?", ele responde direto. Para perguntas complexas ou factuais, ele ativa a busca automaticamente.

Características principais do RAG

- Atualização em tempo real: o conhecimento do sistema pode ser atualizado simplesmente adicionando novos documentos ao banco vetorial, sem precisar retreinar o LLM.
- Redução de alucinações: como o modelo responde baseado em documentos reais, ele "inventa" muito menos informações.
- Rastreabilidade: é possível saber exatamente de qual documento veio cada parte da resposta, o que aumenta a confiança e a transparência.
- Especialização: uma empresa pode criar um sistema RAG com sua própria base de documentos internos, tornando a IA especialista no seu negócio.
- Custo-benefício: é muito mais barato do que treinar um novo modelo do zero, e igualmente eficaz para a maioria dos casos de uso.

Em resumo

O RAG é uma ponte inteligente entre a criatividade dos modelos de linguagem e a precisão das bases de dados. Ele resolve o maior problema da IA generativa — a imprecisão — ancorando as respostas em informações reais e verificáveis. Por isso, hoje é uma das técnicas mais usadas em aplicações profissionais de IA.