

Bancos de Dados Vetoriais

Pesquisa 02 · O que são, como funcionam e principais ferramentas

02 Bancos de Dados Vetoriais

Para entender os bancos vetoriais, primeiro precisamos entender por que os bancos de dados tradicionais não são suficientes para a IA moderna. Um banco de dados comum — como o MySQL ou PostgreSQL — é excelente para guardar informações estruturadas e fazer buscas exatas: "encontre todos os clientes com o nome João". Mas e se você quiser buscar por *significado*?

É aí que entram os bancos de dados vetoriais. Eles foram criados especificamente para guardar e buscar *vetores* — que são, essencialmente, listas de números que representam o significado de textos, imagens, áudios ou qualquer tipo de dado.

O que é um vetor, afinal?

Pense assim: se você tivesse que descrever a personalidade de uma pessoa usando só números de 0 a 1, poderia dizer que ela é "90% extrovertida, 20% tímida, 70% criativa". Isso é um vetor! No mundo da IA, o texto "cachorro late" pode ser representado como uma lista de 384 ou até 1536 números que capturam seu significado. Quanto mais parecidos os significados, mais parecidas as listas de números.

Esse processo de transformar texto (ou imagem, ou áudio) em vetores é feito pelo Embedding Model — que já conhecemos na Pesquisa 1. O banco vetorial é responsável por guardar esses vetores e, principalmente, por encontrar os mais parecidos quando uma nova busca é feita.

Como funciona a busca por similaridade?

Quando você faz uma pergunta a um sistema com RAG, essa pergunta também é transformada em vetor. O banco vetorial então compara esse vetor com todos os que estão guardados e retorna os mais "próximos" — ou seja, os que têm significado mais parecido. Essa operação é chamada de busca por similaridade ou *Approximate Nearest Neighbor (ANN)*.

Para medir a proximidade entre vetores, os bancos utilizam métricas matemáticas. As mais comuns são:

- Similaridade de Cosseno: mede o ângulo entre dois vetores. Quanto menor o ângulo, mais parecidos. É a mais usada em buscas de texto.
- Distância Euclidiana: mede a distância "em linha reta" entre dois pontos no espaço vetorial. É mais intuitiva geometricamente.
- Produto Interno: multiplica e soma os vetores. Rápido e eficiente para certos cenários de recomendação.

Características principais dos bancos vetoriais

- Alta dimensionalidade: os vetores modernos podem ter centenas ou milhares de dimensões, e esses bancos foram otimizados para lidar com isso de forma eficiente.
- Busca semântica: encontram resultados relevantes mesmo que as palavras sejam completamente diferentes — funcionam pelo significado, não pela sintaxe.
- Escalabilidade: são capazes de armazenar e indexar bilhões de vetores, mantendo as buscas rápidas (em milissegundos).
- Filtros combinados: permitem combinar a busca vetorial com filtros tradicionais, como "busque documentos semanticamente parecidos, mas apenas os publicados após 2023".
- Índices especializados: usam estruturas de dados como HNSW (Hierarchical Navigable Small World) para acelerar buscas sem precisar comparar cada vetor individualmente.

Os principais bancos vetoriais do mercado

Qdrant

Desenvolvido em Rust, é conhecido pela altíssima performance e pelo filtro de payload (metadados) muito eficiente. É open-source e tem uma API muito bem documentada. Muito popular em projetos de IA modernos.

Pinecone

Um dos mais populares no mercado. É um serviço gerenciado na nuvem (você não precisa instalar nada), focado em facilidade de uso e escalabilidade. Ideal para quem quer começar rápido.

Weaviate

Open-source com foco em busca semântica. Tem suporte nativo a modelos de embedding e permite fazer buscas vetoriais combinadas com busca por palavras-chave (híbrida).

Chroma

Muito simples de usar e ideal para protótipos e desenvolvimento local. É o favorito de quem está aprendendo RAG, pois funciona sem configuração complicada.

Milvus

Open-source e altamente escalável. Suporta bilhões de vetores e é muito usado em grandes empresas com necessidades complexas de busca em escala.

pgvector

Uma extensão do PostgreSQL que adiciona capacidades vetoriais ao banco relacional já conhecido. Ótimo para quem já usa PostgreSQL e quer adicionar busca semântica sem trocar de tecnologia.

Destaque: O que é o Qdrant?

→ Qdrant

O Qdrant (pronuncia-se "quadrant") é um banco de dados vetorial open-source desenvolvido pela empresa alemã Qdrant Solutions. Ele foi escrito na linguagem Rust, o que o torna extremamente rápido e seguro em termos de uso de memória.

Seus grandes diferenciais são: suporte a filtros por metadados com altíssima eficiência (você pode buscar "vetores parecidos com X, mas apenas os da categoria Y"), suporte a múltiplos vetores por documento, e uma API REST bem estruturada. É muito usado em produção junto com frameworks de IA como LangChain e LlamaIndex. Para quem está estudando IA, o Qdrant é um excelente começo por ter documentação clara e uma versão gratuita na nuvem.

Bancos vetoriais vs. bancos tradicionais

Banco Tradicional (SQL)

Busca por valores exatos. Você pergunta: "me dê todos os registros onde nome = 'João'". Não entende contexto ou significado. Perfeito para dados estruturados e transações.

Banco Vetorial

Busca por proximidade de significado. Você pergunta: "me dê os textos mais parecidos com esta frase". Entende semântica. Perfeito para IA, recomendações e buscas inteligentes.

Onde os bancos vetoriais são usados?

- Chatbots corporativos com RAG: a empresa coloca seus documentos internos no banco vetorial, e o chatbot busca as informações certas para responder perguntas dos funcionários.

- Sistemas de recomendação: plataformas como Spotify e Netflix representam músicas e filmes como vetores para recomendar conteúdo parecido com o que você já gostou.
- Busca semântica: ferramentas de pesquisa que entendem o que você quer dizer, mesmo que você não use as palavras exatas do documento.
- Detecção de imagens similares: buscar fotos parecidas com uma imagem de referência (como o Google Imagens).
- Detecção de plágio e duplicatas: identificar textos com o mesmo significado mesmo que as palavras sejam diferentes.

Em resumo

Os bancos vetoriais são a infraestrutura invisível que torna possível a busca inteligente por significado. Sem eles, o RAG não existiria como conhecemos. Eles são o "arquivo" que guarda o conhecimento em um formato que a IA consegue comparar e recuperar de forma rápida e precisa — não pela letra, mas pelo sentido.

Pesquisa Acadêmica · Inteligência Artificial · Bancos de Dados
Vetoriais

FATESG / SENAI · Autor: Felipe Mendonça Branquinho